

Agente Connect-4: Q-Learning Tabular

Santiago · Fundamentos de IA · Universidad de La Sabana · 2026-1

<https://github.com/10santiago12/Connect-4-IA/tree/guti/groups/Group C SANTI>

1. Idea Principal y Diferenciación

El agente implementa **Q-Learning tabular** — un método de aprendizaje por refuerzo sin modelo (model-free) que aprende la función de valor de acción $q(s, a)$ directamente de la experiencia, sin necesidad de conocer la dinámica del juego. La actualización en cada paso usa bootstrapping:

$$q(s, a) \leftarrow q(s, a) + \alpha * [r + \gamma * \max_{a'} q(s', a') - q(s, a)]$$

Esto lo distingue conceptualmente de los otros dos agentes del grupo:

Agente	Método	Diferencia clave
FiatMonteCarlo	MC online sin tabla	Rollouts aleatorios en cada turno; sin entrenamiento previo
FVMCPolicy	First-Visit MC + tabla	Aprende de episodios completos; actualiza al final de cada partida
QLearningAgent	Q-Learning + lookahead	Actualiza en cada paso (bootstrapping) + búsqueda 3 jugadas adelante en <code>act()</code>

El agente también incorpora una función `score()` en `act()` que simula 3 jugadas adelante para detectar amenazas dobles del oponente y oportunidades de victoria en 2 turnos, y usa **caché pickle** para no reentrenar en cada partida.

2. Análisis de Desempeño

2.1 Variable: color (Rojo vs Amarillo) — oponente aleatorio

Desempeño vs Jugador Aleatorio — 300 partidas por color




Fig. 1 — Win rate vs jugador aleatorio (300 partidas por color)

El agente supera el umbral del 95% en **ambos colores**: 100% como Rojo y 98% como Amarillo. La ligera ventaja de Rojo (mueve primero) es esperada en Connect-4 y consistente con la literatura.

2.2 Variable: oponente = sí mismo (auto-desempeño)




Fig. 2 — Auto-desempeño (200 partidas)




Fig. 3 — Win rate vs episodios de entrenamiento

Auto-desempeño (Fig. 2): el 100% de las partidas terminan en empate cuando el agente juega contra sí mismo. Esto es coherente con la teoría: dos instancias de la misma política determinista convergen al mismo árbol de decisión, produciendo siempre la misma secuencia de jugadas.

2.3 Variable numérica: episodios de entrenamiento

Episodios de entrenamiento (Fig. 3): el agente alcanza el 95% de win rate desde los primeros 1,000 episodios y se mantiene estable al aumentar el presupuesto. Esto indica que la política de Q-Learning con bootstrapping converge rápidamente para este tipo de oponente, a diferencia de Monte Carlo que requiere más muestras.

2.4 Variable: lookahead activado vs desactivado




Fig. 4 — Impacto del lookahead (score 3 jugadas) vs solo Q-table

Lookahead (Fig. 4): activar la función `score()` mejora el win rate de 97.7% a 99.7% como Rojo y de 95.0% a 99.0% como Amarillo. El aporte es más notable en partidas donde el agente debe detectar amenazas dobles que la tabla Q no captura por falta de cobertura en estados avanzados.

3. Propuesta de Mejora




Fig. 5 — Duración por resultado (500 partidas)




Fig. 6 — Cobertura de tabla Q por turno

Cuello de botella identificado:

La Fig. 6 muestra que la cobertura de la tabla Q cae por debajo del 50% a partir del turno 10 y llega a 0% en turnos avanzados. La causa es el tamaño del espacio de estados de Connect-4 (~4 billones de tableros posibles): aunque el agente entrena 110,000 episodios, solo visita una fracción de los estados de turnos medios-tardíos. La Fig. 5 confirma que la única derrota registrada en 500 partidas ocurrió en una partida larga (turno ~23), precisamente donde la cobertura es nula.

Propuesta: función de valor aproximada con features del tablero

En vez de guardar un valor Q por estado exacto (que falla al no haber visto el estado), entrenar una función lineal $q(s,a) \approx w \cdot \phi(s,a)$ donde $\phi(s,a)$ son features del tablero: número de secuencias de 3 fichas, control de columnas centrales, amenazas activas del oponente, etc. Esto permitiría **generalizar** a estados no vistos usando los pesos aprendidos, resolviendo directamente el cuello de botella evidenciado en la Fig. 6. La relación causa-efecto es directa: hoy el agente retorna $q=0.5$ (aleatorio) para cualquier estado no visto; con aproximación lineal retornaría una estimación informada basada en las características del tablero.